

Algebra matricial computacional

Hasta ahora hemos estudiado la deducción y soluciones de la Ecuación General de Advección-Difusión no Estacionaria con Fuente. Tal como surge de las hipótesis esta es una ecuación en el dominio continuo y por lo tanto al resolverla podemos hallar los valores del campo solución en cada uno de los puntos de la geometría en estudio.

Contar con una solución analítica es una gran ventaja pues nos permite saber el valor de la variable en estudio con solo evaluar esta solución en un determinado punto e instante de tiempo, sin embargo este tipo de soluciones es difícil de hallar para geometrías generales. Aquí es donde los métodos numéricos toman importancia dado que es posible obtener soluciones aproximadas (con un error acotado) en cualquier geometría. Como parte de ese proceso es necesario discretizar el problema, es decir definir los puntos de solución y las relaciones entre los valores de la solución en ellos. Esta discretización lleva a sistemas de ecuaciones simultáneas lineales y no lineales cuya solución requiere métodos sencillos y rápidos, los cuales presentaremos en este apartado.

Representación de sistemas lineales de ecuaciones en forma matricial

Un sistema de ecuaciones lineales simultáneas se puede escribir como:

$$A x = b$$

donde A es una matriz de n filas por n columnas, x el vector de las n incógnitas y b un vector n valores conocidos. Podemos escribir también,

$$A_{i,j} x_j = b_i$$

donde,

$$A_{i,j} = \begin{bmatrix} a_{1,1} & a_{1,2} & \cdots & a_{1,n} \\ a_{2,1} & a_{2,2} & \cdots & a_{2,n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n,1} & a_{n,2} & \cdots & a_{n,n} \end{bmatrix} \quad x_j = [x_1 \ x_2 \ \cdots \ x_n] \quad b = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix}$$

Al realizar el producto matriz-vector entre A y x obtenemos,

$$A_{i,j} = \begin{cases} a_{1,1} x_1 + a_{1,2} x_2 + \cdots + a_{1,n} x_n = b_1 \\ a_{2,1} x_1 + a_{2,2} x_2 + \cdots + a_{2,n} x_n = b_2 \\ \vdots + \vdots + \ddots + \vdots = \vdots \\ a_{n,1} x_1 + a_{n,2} x_2 + \cdots + a_{n,n} x_n = b_n \end{cases}$$

que como se ve es un sistema de ecuaciones simultáneas. Para resolver este sistema de ecuaciones podemos proceder en forma directa premultiplicando a ambos lados de la igualdad por A^{-1} , de forma que:

$$A^{-1} A x = A^{-1} b$$

$$x_e = A^{-1} b$$

Lo cual requiere calcular la inversa de la matriz, el problema es resoluble si la matriz es invertible. Cabe remarcar aquí el invertir una matriz requiere $O(n^3)$ operaciones la cual es una cantidad que deseamos reducir. Para fijar ideas si utilizamos un procesador AMD Ryzen 7 con una potencia de cálculo de 1830 GFlops (10^9 operaciones de coma flotante por segundo) para resolver un problema usual de Mecánica de Fluidos Computacional de 3 millones de incógnitas el tiempo necesario es de aproximadamente 171 días. Como vemos es completamente inviable.

Otra cantidad muy importante que utilizaremos es el residuo, definido como,

$$R = A x - b$$

para el caso de la solución exacta se tiene,

$$R = A x_e - b = A A^{-1} b - b = I b - b = 0$$

es decir el residuo es nulo el en caso de hallar la solución exacta, y no nulo en cualquier otro caso. Es importante destacar que a los fines de determinar si hemos encontrado la solución, el residuo es una medida concreta y útil que no requiere conocer la solución exacta.

Norma de una matriz. Matriz simétrica y definida positiva

Definiremos ahora la **norma de una matriz**, cantidad que será de utilidad al tratar con métodos de resolución de sistemas lineales en forma no directa. Una norma es simplemente un número real que se obtiene operando sobre la matriz. Así pues definimos norma de la matriz A , $\|A\|$ ^{1 2}, como una cantidad que satisface las siguientes condiciones,

- $\|A\| > 0$ si $A \neq 0$ y $\|A\| = 0 \Leftrightarrow A = 0$
- $\|\alpha A\| = |\alpha| \|A\|$ para todo $\alpha \in \mathbb{R}$
- $\|A + B\| \leq \|A\| + \|B\|$

La primera condición implica que la norma de una matriz es cero solamente si la matriz es nula, es decir una matriz solamente con coeficientes nulos. En cuanto a la última, es la conocida "desigualdad triangular". Contando con una norma para vectores podemos definir una norma para matrices de la siguiente forma,

$$\|A\| = \max_{\|x\|=1} \|A x\|$$

Algunas normas usuales son las siguientes,

- Norma 2. $\|A\|_2 = \sqrt{\text{máx eig}(A^T A)}$
- Norma infinito. $\|A\|_\infty = \text{máx}_i \left(\sum_j |a_{ij}| \right)$
- Norma 1. $\|A\|_1 = \text{máx}_j \left(\sum_i |a_{ij}| \right)$

¹Wikipedia: Norma Matricial

²Mario Storti y Rodrigo Paz. Métodos iterativos para la solución de problemas lineales y no-lineales. Notas del curso

Siendo la norma infinito el máximo en filas de la suma por columnas de los valores absolutos de los elementos de la matriz, lo contrario para la norma uno. Se deja como ejercicio demostrar que estas tres normas cumplen las condiciones requeridas para serlo. Las normas matriciales obtenidas a partir normas vectoriales cumplen además la siguiente desigualdad,

$$\|A B\| \leq \|A\| \|B\|$$

Podemos definir ahora el **número de condición** como

$$\kappa(A) = \|A\| \|A^{-1}\|$$

Utilizando las definiciones previas tenemos,

$$1 = \|I\| = \|A A^{-1}\| \leq \|A\| \|A^{-1}\| = \kappa(A)$$

vemos que el número de condición para toda matriz no nula y diferente de la identidad es mayor o igual a uno. Para el caso de una matriz singular, es decir que no tiene inversa, se considera que su número de condición tiende a infinito. Cuando el número de condición de una matriz es pequeño se dice que está *bien condicionada*, por el contrario en el caso de números de condición grandes se encuentra *mal condicionada*. De la ayuda de octave tenemos que “El número de condición cuantifica la sensibilidad de una operación de inversión de matrices ante pequeños cambios en los elementos de la matriz. Idealmente el número de condición debe ser cercano a 1. Cuando el número de condición es grande esto indica que pequeños cambios tales como el cero de máquina o los errores de redondeo producirán grandes cambios en los resultados. En tales casos las soluciones obtenidas por métodos numéricos tenderán a no ser precisas”. La importancia de este número quedará más clara en breve.

Finalmente definimos **matriz simétrica definida positiva (spd)** como aquella matriz simétrica, es decir que cumple,

$$A = A^T, \quad A - A^T = 0$$

y que además posee solamente autovalores positivos.

Métodos directos

Entre los métodos para resolver sistemas de ecuaciones lineales se encuentran los directos, es decir aquellos que mediante una secuencia de operaciones encuentran la solución exacta al problema. Uno de los más conocidos en la eliminación gaussiana o eliminación de Gauss-Jordan. Este método permite hallar la solución a un sistema de ecuaciones o bien la inversa de una matriz por medio de operaciones de suma, resta y multiplicación por un escalar de filas o columnas, en los cursos de Algebra se lo conoce también como métodos de sumas y restas. Como se indicó más arriba es un método inviable para grandes matrices, pero es de ayuda en conjunto con métodos aproximados.

Otro método directo muy utilizado es la sustitución hacia adelante o hacia atrás a partir de una descomposición LU. Esta descomposición o factorización implica obtener una matriz triangular inferior con *diagonal unitaria*, L , y otra matriz triangular superior con *diagonal unitaria* U tal que,

$$A x = L U x = b$$

Para realizar esta factorización se utilizan técnicas derivadas de la eliminación gaussiana con complejidad algorítmica $O(n^3)$. Luego podemos hacer,

$$L(Ux) = b$$

llamando $Ux = y$ nos queda,

$$Ly = b$$

Resolvemos entonces primero para y y queda pendiente,

$$Ux = y$$

donde finalmente resolvemos para x . La ventaja al resolver estos últimos dos sistemas de ecuaciones es que la sustitución hacia adelante o hacia atrás es una operación de complejidad algorítmica $O(n^2)$. Así pues si debemos resolver en forma repetida sistemas de ecuaciones con la misma matriz pero distinto lado derecho, b , podemos invertir la matriz del problema y luego realizar un producto matriz-vector con cada nuevo b , el cual es una operación $O(n^3)$, con lo cual el procedimiento completo será $O(n^3)$. Si en cambio factorizamos la matriz en L y U y utilizamos el procedimiento anterior la complejidad algorítmica será: $O(n^3 + n^2)$.

Métodos iterativos

Son métodos de resolución de ecuaciones lineales basados en la aplicación de una determinada regla en forma repetitiva. De esta manera se genera una secuencia o sucesión de valores que debe *converger* a la solución del sistema de ecuaciones. Partiendo de una solución inicial x_0 tendremos entonces la secuencia,

$$x_0, x_1, x_2, x_3, \dots, x_k, x_{k+1} \dots$$

que puede escribirse como

$$\{x_k\}_{k=0}^{\infty}$$

donde desde ya buscamos que,

$$\lim_{k \rightarrow \infty} x_k = x_c$$

Si este límite existe y además $x_c = x_e$ entonces decimos que el método *converge*. Esto da lugar a dos posibles resultados inválidos, uno es que el método diverja, es decir que los valores crezcan indefinidamente, o bien que el método converja pero lo haga a un valor que no es la solución exacta. Nótese que, como indicamos antes, no conocemos el valor de x_e con lo cual no es posible determinar en forma directa si el método ha convergido o no, a menos que diverja. Ahora bien podemos hacer,

$$\lim_{k \rightarrow \infty} Ax_k - b = Ax_e - b = 0$$

o, lo que es lo mismo,

$$\lim_{k \rightarrow \infty} R_k = 0$$

Es decir el residuo debe tender a cero a medida que el método converge.

Métodos iterativos estacionarios

Los métodos iterativos presentados en forma general en la sección anterior puede dividirse en *Métodos Iterativos Estacionarios* y *Métodos Iterativos no Estacionarios*, en los primeros el valor de la próxima estimación de la solución, x_{k+1} solo depende del valor actual, x_k , es decir $x_{k+1} = f(x_k)$ mientras que en los segundos, hay una dependencia con la historia anterior de la solución, es decir $x_{k+1} = f(x_k, x_{k-1}, x_{k-2}, \dots)$. Como primer método estacionario estudiaremos el **método de Richardson**,

$$x_{k+1} = (I - A) x_k + b$$

que puede escribirse en general como,

$$x_{k+1} = M x_k + c$$

$M = I - A$ es la *matriz de amplificación*, de las propiedades de esta matriz depende si el método converge o no. En este caso la iteración convergerá si $\|M\|_2 \leq 1$. Podemos escribir también,

$$x_{k+1} = x_k + (b - A x_k) = x_k - r_k$$

de donde se ve que la nueva solución se obtiene como la actual con una corrección dada por el residuo. Este método puede *relajarse* para mejorar la convergencia como,

$$x_{k+1} = x_k - \omega r_k$$

donde ω se denomina coeficiente de relajación. Para el caso de matrices spd se puede demostrar que el coeficiente de relación óptimo es,

$$\omega_{\text{opt}} = \frac{2}{\lambda_{\max} + \lambda_{\min}}$$

siendo λ los autovalores de la matriz A .

El segundo método que presentaremos es la **Iteración de Gauss-Seidel** donde la matriz de amplificación es,

$$M = -(D + L)^{-1} U \quad c = (D + L)^{-1} b$$

siendo D la matriz diagonal de A y L y U matrices triangulares con *diagonal nula*, tales que $A = D + L + U$.

Métodos iterativos no estacionarios. Gradientes conjugados.

Como método iterativo no estacionario modelo estudiaremos el **Método de Gradientes Conjugados**. Este método puede plantearse como un método directo con fines didácticos, aunque en la práctica no es muy útil en esta forma. Primero diremos que dos vectores, u y v son *conjugados*³ con respecto a la matriz A si,

$$u^T A v = 0$$

Suponiendo que A es spd esta operación conforma un producto escalar, que podemos denotar como,

$$u^T A v = \langle u, v \rangle_A$$

³Wikipedia: Conjugate Gradient Method

el que dos vectores u, v posean producto punto nulo implica que son ortogonales, tomando n vectores ortogonales entre si bajo esta norma podemos conformar una base en el espacio $\mathbb{R}^n$ y escribir la solución del problema en esta base,

$$x_e = \sum_{i=1}^n \alpha_i p_i$$

donde los p_i forman la base en cuestión. Multiplicando a ambos lados por A tenemos

$$A x_e = \sum_{i=1}^n \alpha_i A p_i$$

Multiplicando ahora a izquierda (es decir haciendo el producto punto),

$$p_k^T A x_e = \sum_{i=1}^n \alpha_i p_k^T A p_i$$

reemplazando $A x_e = b$ y utilizando la notación del producto escalar definido nos queda,

$$p_k^T b = \sum_{i=1}^n \alpha_i \langle p_k, p_i \rangle_A$$

Dado que $\langle p_k, p_i \rangle_A = 0 \forall i \neq k$ esto implica que,

$$\langle p_k^T, b \rangle = \alpha_k \langle p_k, p_k \rangle_A$$

despejando,

$$\alpha_k = \frac{\langle p_k^T, b \rangle}{\langle p_k, p_k \rangle_A}$$

donde $\langle p_k^T, b \rangle$ es el producto escalar usualmente utilizado. Resolver el sistema de ecuaciones $A x = b$ implica hallar primeramente la base de vectores p_k para luego hallar los correspondientes coeficientes α_k .

Es posible encontrar los p_k en secuencia para conformar un método iterativo. Comenzando a partir de una solución inicial, x_0 es necesario encontrar una manera para saber si estamos acercándonos a la solución exacta x_e la cual es desconocida. Para ello es necesario establecer una métrica. Podemos encontrar una métrica a partir del hecho que la solución exacta al problema planteado minimiza la siguiente función cuadrática,

$$f(x) = \frac{1}{2} x^T A x - x^T b \quad \text{con } x \in \mathbb{R}^n$$

minimizar esta función implica que,

$$\nabla f(x) = A x - b = 0$$

Podemos pensar el problema como un paraboloide elíptico n dimensional donde la solución está en el punto de mínimo. El gradiente calculado en un determinado punto marca la dirección de máximo crecimiento a partir de ese punto. El primer vector de la base, p_0 , podemos entonces tomarlo como el opuesto al gradiente calculado en este punto $p_0 = -(A x - b) = b - A x_0$, los restantes vectores en la base serán conjugados respecto de este, de aquí el nombre de *Método de gradientes conjugados*. Nótese que p_0 es el residuo

correspondiente al paso inicial del método de solución. Una manera de computar un nuevo vector p_k conjugado según la norma A es la siguiente,

$$p_k = r_k - \sum_{i < k} \frac{p_i^T A r_k}{p_i^T A p_i} p_i$$

Disponiendo de esta dirección podemos computar la nueva aproximación para x como,

$$x_{k+1} = x_k + \alpha_k p_k$$

siendo α_k ,

$$\alpha_k = \frac{\langle p_k^T, r_k \rangle}{\langle p_k, p_k \rangle_A}$$

Nótese que para el cálculo de p_k hemos utilizado los vectores de la base anteriormente obtenidos con lo que queda claro que el método es no estacionario, es decir que depende de la historia de búsqueda de la solución. Si bien este método halla la solución en n pasos, lo cual es atractivo para sistemas de pocas ecuaciones, se vuelve prohibitivo en el caso de millones de incógnitas. Afortunadamente la convergencia es muy buena y es posible hallar soluciones con errores muy pequeños con cantidades razonables de operaciones. Si bien el método formalmente requiere operaciones de producto matriz-vector, las cuales son $O(n^3)$, esta cantidad de operaciones se reduce en forma drástica para el caso de matrices ralas (con pocos valores no nulos, comunes en problemas de discretización de ecuaciones diferenciales), lo cual no sucede con los métodos directos como la eliminación gaussiana o la factorización LU.

Podemos entonces escribir un algoritmo básico para Gradientes Conjugados, partiendo de una solución inicial x_0 como,

```

 $r_0 = b - A x_0$ 
si  $\langle r_0 \rangle$  es suficientemente pequeño retornar  $x_0$  como resultado
 $p_0 = r_0$ 
 $k = 0$ 
repetir
     $\alpha_k = \frac{r_k^T r_k}{p_k^T A p_k}$ 
     $x_{k+1} = x_k + \alpha_k p_k$ 
     $r_{k+1} = r_k - \alpha_k A p_k$ 
    si  $\langle r_{k+1} \rangle$  es suficientemente pequeño retornar, salir del bucle
     $\beta_k = \frac{r_{k+1}^T r_{k+1}}{r_k^T r_k}$ 
     $p_{k+1} = r_{k+1} + \beta_k p_k$ 
     $k = k + 1$ 
fin repetir
retornar  $x_{k+1}$  como resultado

```

Ejercicios. Utilizando las definiciones de los métodos presentadas en el texto resolver las siguientes consignas:

1. Realizar las demostraciones que se dejaron como ejercicio.
2. Sea una cuadrícula de m columnas por m filas, enumerada por filas desde su parte superior hacia abajo, construir una matriz de conectividades que asigne el valor -1 a

todos los elementos cuya fila y columna correspondan a dos celdas de la cuadrícula conectadas. En la diagonal asignar el número 4. Realizar entonces las siguientes tareas,

- a) ¿Identifica este tipo de matrices en problemas que ha resuelto anteriormente? Desarrolle.
- b) Para el caso de $m = 3$ calcule el número de condición para la matriz original y luego utilizando la misma matriz pero con la diagonal escalada por 1×10^{-15} , 1×10^{-12} , 1×10^{-9} , 1×10^{-6} , 1×10^{-3} y 1×10^1 . Interprete.
- c) En los casos anteriores asumir como solución de un sistema un vector de unos y calcular el lado derecho, b , como $b = Ax$. Luego computar la solución usando la barra invertida de octave y calcular el error respecto de la solución exacta como,

$$e = A \backslash b - x$$

¿Qué relación encuentra entre el número de condición de las matrices y el error respecto de la solución exacta?

3. Para la matriz base utilizada previamente demostrar a través de comandos de octave que es spd.
4. Tomando como matriz el caso de $m = 20$, usando un factor de escala de $1/(m \cdot m)$, lado derecho $\underline{b} = 1/(m \cdot m)$ y solución inicial $\underline{x}_0 = 1$ resolver el sistema por medio del método de Richardson para distintos factores de relajación mayores, menores e iguales a la relajación óptima. Presentar un gráfico r vs. iteraciones utilizando la norma usual para vectores y escala logarítmica para el residuo.
5. Presentar una comparación mediante un gráfico similar al anterior para el caso del método de Richardson con relajación óptima, el método de Gauss-Seidel y el método de Gradientes Conjugados. Comparar la cantidad de iteraciones necesarias para alcanzar la precisión de máquina en el residuo.
6. Dibujar en un gráfico 2D la evolución de las dos primeras componentes de la solución para los tres métodos iterativos partiendo desde la solución inicial.
7. A partir de la implementación del método de Gradientes Conjugados previamente realizada extenderla para la utilización de preconditionadores. Realizar una gráfica de evolución del residuo para el caso sin preconditionamiento así como para las variantes Cholesky Incompleto y Cholesky Incompleto modificado. Para generar estas matrices dispone del comandod `ichol` de octave. Recordar que la factorización de Cholesky es aquella que permite hallar $M = LL^T$ (siendo L una matriz diagonal) y que la solución de sistemas del tipo $La = r$ al realizarse en octave se valen de la subsitución hacia atras, la cual es una operación eficiente. Obtener conclusiones.
8. Implementar un resolvidor directo por eliminación gaussiana que devuelva el vector solución y la cantidad total de operaciones efectuadas. Comprobar su funcionamiento con un sistema de ecuaciones modelo. Una vez verificado su funcionamiento generar matrices y vectores lado derecho aleatorios con n desde 2 hasta 40 incognitas y almacenar para cada caso la cantidad de operaciones efectuadas. Utilizando el comando `polyfit` de octave ajustar un polinomio $P(n)$ a los resultados y comprobar si el grado del polinomio coincide con las predicciones teóricas de complejidad algorítmica. Graficar `nops.` vs n uniendo con líneas $P(n)$ vs. n . con círculos para verificar que el ajuste es correcto.